

LDA 推导

Soul Walker

2020 年 7 月 22 日

给定数据矩阵 $\mathbf{X} = (\mathbf{x}_1; \mathbf{x}_2; \cdots; \mathbf{x}_n) \in R^{n \times m}$, 标签矩阵 $\mathbf{Y} = (y_1, y_2, \cdots, y_n)$, $X_i (i = 1, 2, \cdots, k)$ 为属于第 i 类的样本集合, $n_i (i = 1, 2, \cdots, k)$ 为属于第 i 类的样本个数, 训练数据集

$$T = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \cdots, (\mathbf{x}_n, y_n)\} = \{(\mathbf{x}_i, y_i)\}_{i=1}^n$$

其中, $y_i \in \{C_1, C_2, \cdots, C_k\}$ 为实例的类别。定义 $\boldsymbol{\mu}_i (i = 1, 2, \cdots, k)$ 为第 i 类样本的均值向量, 定义样本整体均值 $\boldsymbol{\mu}$, $\boldsymbol{\Sigma}_i (i = 1, 2, \cdots, k)$ 为第 i 类样本的协方差矩阵, 并且我们希望将数据降到 d 维。

0.1 散度矩阵

首先我们定义变换

$$f(\mathbf{x}_i) = \mathbf{w}^T \mathbf{x}_i \in R^d (d \leq k - 1) \quad (0.1)$$

其中 $\mathbf{w} \in R^{n \times d}$, 对于 $d < k - 1$ 的问题有如下解释, 因为 S_b (后文做推导) 中每个 $\boldsymbol{\mu}_i - \boldsymbol{\mu}$ 的秩 (rank) 为 1, 因此相加后的协方差矩阵秩小于等于 k , 但是我们知道前 $k - 1$ 个 $\boldsymbol{\mu}_i$ 之后, 最后一个 $\boldsymbol{\mu}_k$ 可以由前 $k - 1$ 个 $\boldsymbol{\mu}_i$ 线性表示, 因此 $d \leq k - 1$ 成立

我们的目标是使得类内距离小, 类间距离大。

对于类内 (协方差矩阵):

$$\begin{aligned} & \sum_{i \in C_k} (\mathbf{w}^T \mathbf{x}_i - \mathbf{w}^T \boldsymbol{\mu}_k)(\mathbf{w}^T \mathbf{x}_i - \mathbf{w}^T \boldsymbol{\mu}_k)^T \\ &= \mathbf{w}^T \sum_{i \in C_k} (\mathbf{x}_i - \boldsymbol{\mu}_k)(\mathbf{x}_i - \boldsymbol{\mu}_k)^T \mathbf{w} \end{aligned} \quad (0.2)$$

其中我们定义 $S_k = \sum_{i \in C_k} (\mathbf{x}_i - \boldsymbol{\mu}_k)(\mathbf{x}_i - \boldsymbol{\mu}_k)^T$ ，上式可以做如下变换

$$\begin{aligned}
& \mathbf{w}^T \sum_{i \in C_k} (\mathbf{x}_i - \boldsymbol{\mu}_k)(\mathbf{x}_i - \boldsymbol{\mu}_k)^T \mathbf{w} \\
&= \text{tr}(\mathbf{w}^T S_k \mathbf{w}) \\
&= \text{tr}(\mathbf{w}^T \sum_{i=1}^k S_i \mathbf{w})
\end{aligned} \tag{0.3}$$

我们令 $S_w = \sum_{i=1}^k S_i$ ，这里称 S_w 为类内散度矩阵，那么上式最终变换得

$$\sum_{i \in C_k} (\mathbf{w}^T \mathbf{x}_i - \mathbf{w}^T \boldsymbol{\mu}_k)(\mathbf{w}^T \mathbf{x}_i - \mathbf{w}^T \boldsymbol{\mu}_k)^T = \text{tr}(\mathbf{w}^T S_w \mathbf{w}) \tag{0.4}$$

对于类间（协方差矩阵）：

$$\begin{aligned}
d_i &= (\mathbf{w}^T \boldsymbol{\mu}_i - \mathbf{w}^T \boldsymbol{\mu})(\mathbf{w}^T \boldsymbol{\mu}_i - \mathbf{w}^T \boldsymbol{\mu})^T \\
&= (\boldsymbol{\mu}_i - \boldsymbol{\mu})^T \mathbf{w} \mathbf{w}^T (\boldsymbol{\mu}_i - \boldsymbol{\mu})
\end{aligned} \tag{0.5}$$

我们令 $\mathbf{M} = (\boldsymbol{\mu}_1, \dots, \boldsymbol{\mu}_k)$ ， $\bar{\mathbf{M}} = (\boldsymbol{\mu}, \dots, \boldsymbol{\mu})$

$$\begin{aligned}
& \sum_{i=1}^k d_i \\
&= \sum_{i=1}^k (\boldsymbol{\mu}_i - \boldsymbol{\mu})^T \mathbf{w} \mathbf{w}^T (\boldsymbol{\mu}_i - \boldsymbol{\mu}) \\
&= \text{tr}((\mathbf{M} - \bar{\mathbf{M}})^T \mathbf{w} \mathbf{w}^T (\mathbf{M} - \bar{\mathbf{M}})) \\
&= \text{tr}(\mathbf{w}^T (\mathbf{M} - \bar{\mathbf{M}})(\mathbf{M} - \bar{\mathbf{M}})^T \mathbf{w})
\end{aligned} \tag{0.6}$$

这里我们令 $S_b = (\mathbf{M} - \bar{\mathbf{M}})(\mathbf{M} - \bar{\mathbf{M}})^T$ ，这里 S_b 称为类间散度矩阵，那么上式最终变换得

$$\sum_{i=1}^k d_i = \text{tr}(\mathbf{w}^T S_b \mathbf{w}) \tag{0.7}$$

0.2 目标及求解

我们的目标是使得类内距离小，类间距离大，即最优化问题：

$$\max_{\mathbf{w}} \frac{\text{tr}(\mathbf{w}^T S_b \mathbf{w})}{\text{tr}(\mathbf{w}^T S_w \mathbf{w})} \tag{0.8}$$

那么我们的约束最优化问题为

$$\begin{cases} \max_{\mathbf{w}} \text{tr}(\mathbf{w}^T S_b \mathbf{w}) \\ s.t. \quad \text{tr}(\mathbf{w}^T S_w \mathbf{w}) = d \end{cases} \quad (0.9)$$

对上式求解可以使用拉格朗日乘子法如下

$$L(\mathbf{w}, \mathbf{\Lambda}) = \text{tr}(\mathbf{w}^T S_b \mathbf{w}) - \text{tr}(\mathbf{w}^T S_w \mathbf{w} \mathbf{\Lambda}) \quad (0.10)$$

其中

$$\mathbf{\Lambda} = \begin{bmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_d \end{bmatrix} \quad (0.11)$$

对上式求偏导得

$$\begin{aligned} \frac{\partial L(\mathbf{w}, \mathbf{\Lambda})}{\partial \mathbf{w}} &= 0 \\ S_b \mathbf{w} &= S_w \mathbf{w} \mathbf{\Lambda} \\ S_w^{-1} S_b \mathbf{w} &= S_w^{-1} S_w \mathbf{w} \mathbf{\Lambda} \\ S_w^{-1} S_b \mathbf{w} &= \mathbf{w} \mathbf{\Lambda} \end{aligned} \quad (0.12)$$

那么 \mathbf{w} 的求解由 $S_w^{-1} S_b$ 的最大的 k 个特征向量组成。

这里有一个小问题：对于 S_w 是否可逆的讨论，如果不可逆的话可进行：

- 1 . $S_w + I_d \cdot 0.001$ (or else);
- 2 . 先做 PCA。