

Support Vector Machine 推导

Soul Walker

2020 年 7 月 22 日

1 Support Vector Machine

SVM 有三种情况及其处理手段:

1. 线性可分问题: Hard-Margin SVM
2. 线性可分但是有一点错误: Soft-Margin SVM
3. 非线性问题: Kernel SVM

NOTE: SMO 算法是支持向量机学习的一种快速算法

1.1 模型定义

首先我们定义数据如下

输入: 训练数据集

$$T = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_N, y_N)\} = \{(\mathbf{x}_i, y_i)\}_{i=1}^N$$

其中, $\mathbf{x}_i \in \chi \in \mathbb{R}^N$ 为实例的特征向量, $\mathbf{x}_i = (\mathbf{x}_i^{(1)}, \mathbf{x}_i^{(2)}, \dots, \mathbf{x}_i^{(n)})^T$, $y_i \in \{+1, -1\}$ 为实例的类别, $i = 1, 2, \dots, N$, 实例特征向量 \mathbf{x} , \mathbf{X} 为训练样本集, 形状为 (N, p) , \mathbf{Y} 是训练标签集, 形状为 $(N, 1)$ 。这里我们使用 α 来作为拉格朗日乘子。

输出: 实例 \mathbf{x} 所属的类别 y 。

SVM (最大间隔分类器) 的分类决策函数为 $f(\mathbf{x}) = \text{sign}(w^* \cdot \mathbf{x} + b^*)$, 其中 w^*, b^* 是 w 和 b 的最优解。

由名称(最大间隔分类器)拆分解: 1. 最大: \max 2. 间隔 (数据和直线的距离的最小值): $\text{margin}(w, b)$ 3. 分类器: $y_i(w^T \mathbf{x}_i + b) > 0 \quad \forall i = 1, \dots, N$

对于分类器的推导:

$$\begin{cases} w^T \mathbf{x}_i + b > 0, y_i = +1 \\ w^T \mathbf{x}_i + b < 0, y_i = -1 \end{cases}$$

那么分类正确的条件是 $y_i(w^T \mathbf{x}_i + b) > 0$ 。

对于间隔的推导:

定义点 (\mathbf{x}_i, y_i) 到直线 $f(\mathbf{x}) = w^T \mathbf{x} + b$ 的距离 $distance(w, b, \mathbf{x}_i) = \frac{1}{\|w\|} |w^T \mathbf{x}_i + b|$

$$\begin{aligned} & margin(w, b) \\ &= \min_{w, b, \mathbf{x}_i} distance(w, b, \mathbf{x}_i) \\ &= \min_{w, b, \mathbf{x}_i} \frac{1}{\|w\|} |w^T \mathbf{x}_i + b| \end{aligned}$$

综合以上推导：

$$\begin{aligned} & \max_{w, b} \min_{\mathbf{x}_i} \frac{1}{\|w\|} |w^T \mathbf{x}_i + b| \\ \Rightarrow & \max_{w, b} \min_{\mathbf{x}_i} \frac{1}{\|w\|} y_i (w^T \mathbf{x}_i + b) \\ \Rightarrow & \max_{w, b} \frac{1}{\|w\|} \min_{\mathbf{x}_i} y_i (w^T \mathbf{x}_i + b) \end{aligned}$$

令

$$\gamma = \min_{\mathbf{x}_i} y_i (w^T \mathbf{x}_i + b) = 1$$

那么

$$\begin{aligned} y_i (w^T \mathbf{x}_i + b) > 0 & \Rightarrow \gamma > 0 \quad s.t. \quad \min_{\mathbf{x}_i y_i} (w^T \mathbf{x}_i + b) = \gamma \\ \Rightarrow & \begin{cases} \max_{w, b} \frac{1}{\|w\|} \\ s.t. \quad y_i (w^T \mathbf{x}_i + b) = 1 \end{cases} \end{aligned}$$

可以转换为最小化问题（优化问题且是 Convex Optimization（凸优化）问题）：

$$\begin{cases} \min_{w, b} \|w\| = \min_{w, b} \frac{1}{2} w^T w \\ s.t. \quad y_i (w^T x_i + b) \geq 1 \quad \forall i = 1, 2, \dots, N \end{cases}$$

1.2 Hard-Margin SVM 求解

带约束问题：

$$\begin{cases} \min_{w, b} \frac{1}{2} w^T w \\ s.t. \quad y_i (w^T \mathbf{x}_i + b) \geq 1 \Leftrightarrow 1 - y_i (w^T \mathbf{x}_i + b) \leq 0 \quad \forall i = 1, 2, \dots, N \end{cases} \quad (1)$$

可以得到拉格朗日函数 (Lagrange function)

$$\mathfrak{L}(w, b, \alpha) = \frac{1}{2} w^T w + \sum_{i=1}^N \alpha_i (1 - y_i (w^T x_i + b)) \quad (2)$$

于是得到

$$\begin{cases} \min_{w, b} \max_{\alpha} \mathfrak{L}(w, b, \alpha) \\ s.t. \quad \alpha_i \geq 0 \end{cases} \quad (3)$$

此处我们展开

$$\begin{cases} \text{when } 1 - y_i(w^T \mathbf{x}_i + b) > 0, & \max_{\alpha} \mathfrak{L}(w, b, \alpha) = \frac{1}{2}w^T w + \infty = +\infty \\ \text{when } 1 - y_i(w^T \mathbf{x}_i + b) \leq 0, & \max_{\alpha} \mathfrak{L}(w, b, \alpha) = \frac{1}{2}w^T w + 0 = \frac{1}{2}w^T w \end{cases} \quad (4)$$

对于第一个公式取到 ∞ 所以无意义，舍弃；第二个公式可以得到最优解出处

$$\min_{w, b} \max_{\alpha} \mathfrak{L}(w, b, \alpha) = \min_{w, b} \frac{1}{2}w^T w \quad (5)$$

因此综合上述三个公式可以推导出

$$\min_{w, b} \max_{\alpha} \mathfrak{L}(w, b, \alpha) = \min_{w, b} (\infty, \frac{1}{2}w^T w) = \min_{w, b} \frac{1}{2}w^T w \quad (6)$$

对于式 (3) 的对偶问题

$$\begin{cases} \max_{\alpha} \min_{w, b} \mathfrak{L}(w, b, \alpha) \\ \text{s.t. } \alpha_i \geq 0 \end{cases} \quad (7)$$

对于式 (7) 的求解如下

Step1

$$\begin{aligned} \text{let } 0 &= \frac{\partial \mathfrak{L}}{\partial b} = \frac{\partial}{\partial b} \left[\sum_{i=1}^N \alpha_i - \sum_{i=1}^N \alpha_i y_i (w^T \mathbf{x}_i + b) \right] \\ &= \frac{\partial}{\partial b} \left[- \sum_{i=1}^N \alpha_i y_i b \right] \\ &= - \sum_{i=1}^N \alpha_i y_i \end{aligned} \quad (8)$$

所以可得 $\sum_{i=1}^N \alpha_i y_i = 0$ ，将其代入 $\mathfrak{L}(w, b, \alpha)$ 式 (2) 可得

$$\begin{aligned} \mathfrak{L}(w, b, \alpha) &= \frac{1}{2}w^T w + \sum_{i=1}^N \alpha_i - \sum_{i=1}^N \alpha_i y_i (w^T \mathbf{x}_i + b) \\ &= \frac{1}{2}w^T w + \sum_{i=1}^N \alpha_i - \sum_{i=1}^N \alpha_i y_i w^T \mathbf{x}_i + \sum_{i=1}^N \alpha_i y_i b \\ &= \frac{1}{2}w^T w + \sum_{i=1}^N \alpha_i - \sum_{i=1}^N \alpha_i y_i w^T \mathbf{x}_i \end{aligned} \quad (9)$$

Step2

$$\begin{aligned} \text{let } 0 &= \frac{\partial \mathfrak{L}}{\partial w} = \frac{1}{2}2w - \sum_{i=1}^N \alpha_i y_i \mathbf{x}_i \\ w^* &= \sum_{i=1}^N \alpha_i y_i \mathbf{x}_i \end{aligned} \quad (10)$$

将其带入 $\mathfrak{L}(w, b, \alpha)$ 式 (9) 可得

$$\begin{aligned} \mathfrak{L}(w, b, \alpha) &= \frac{1}{2} \left(\sum_{i=1}^N \alpha_i y_i \mathbf{x}_i \right)^T \left(\sum_{j=1}^N \alpha_j y_j \mathbf{x}_j \right) - \sum_{i=1}^N \alpha_i y_i \left(\sum_{j=1}^N \alpha_j y_j \mathbf{x}_j \right)^T \mathbf{x}_i + \sum_{i=1}^N \alpha_i \\ &= -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j + \sum_{i=1}^N \alpha_i \end{aligned} \quad (11)$$

最后，结合式 (11) 可得

$$\begin{cases} \max_{\alpha} & -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j + \sum_{i=1}^N \alpha_i \\ \text{s.t.} & \alpha_i \geq 0 \end{cases} \quad (12)$$

求解的步骤为式 (1)-> 式 (3)-> 式 (7)-> 式 (12)

而我们通过以上求解可以得出一点结论：非支持向量点满足 $1 - y_i(w^T \mathbf{x}_i + b) > 0$ ，则为了满足 KKT 条件的话， $\alpha_i = 0$ 必须成立，也就是说非支持向量点在对 w^*, b^* 的求解问题上无贡献，求解时，他们没有任何用处。

KKT 条件

$$\begin{cases} \frac{\partial \mathcal{L}}{\partial w} = 0 & \frac{\partial \mathcal{L}}{\partial b} = 0 \\ \alpha_i (1 - y_i(w^T \mathbf{x}_i + b)) = 0 \\ \alpha_i \geq 0 \\ 1 - y_i(w^T \mathbf{x}_i + b) \leq 0 \end{cases} \quad (13)$$

$\Rightarrow w^*, b^*$

$$w^* = \sum_{i=1}^N \alpha_i y_i \mathbf{x}_i \quad (14)$$

$$\begin{aligned} & \exists (\mathbf{x}_k, y_k), \text{s.t. } 1 - y_k(w^T \mathbf{x}_k + b) = 0 \\ \Rightarrow & y_k(w^T \mathbf{x}_k + b) = 1 \\ & y_k^2(w^T \mathbf{x}_k + b) = y_k \\ & b^* = y_k - w^T \mathbf{x}_k \\ & = y_k - \frac{v}{\mathbf{x}_i} \lambda_i y_i \mathbf{x}_i^T \mathbf{x}_k \end{aligned} \quad (15)$$

那么联立以上公式可得 w^*, b^* 的求解

$$\begin{cases} w^* = \sum_{i=1}^N \alpha_i y_i \mathbf{x}_i \\ b^* = y_k - \sum_{i=1}^N \alpha_i y_i \mathbf{x}_i^T \mathbf{x}_k \end{cases} \quad (16)$$

那么通过分类器 $f(\mathbf{x}) = \text{sign}(w^* \mathbf{x} + b^*)$ 可以进行分类，此时划分超平面就是 $w^{*T} \mathbf{x} + b^* = 0$

1.3 Soft-Margin SVM 求解

此处 Soft-Margin SVM 指的是处理线性不可分或可分但存在噪声的数据。Soft：允许一点点错误所以此处由硬间隔约束问题 (1) 可得此处可以转换为 $\min_{w,b} \frac{1}{2} w^T w + \text{loss}$ ，此处的讨论为 loss 。我们有以下：

1.loss 使用犯错个数：

$$\text{loss} = \sum_{i=1}^N I \{y_i (w^T \mathbf{x}_i + b) < 1\} \quad (17)$$

但此处指示函数 (I) 关于 w 不连续令 $z = y(w^T \mathbf{x}_i + b)$ 那么此处取 **0-1 损失函数**

$$loss_{0-1} = \begin{cases} 1, & z \leq 1 \\ 0, & otherwise \end{cases} \quad (18)$$

2.loss 使用距离: Hinge-Loss

$$\begin{cases} \text{when } y_i(w^T \mathbf{x}_i + b) \geq 1, \text{ let } loss = 0 \\ \text{when } y_i(w^T \mathbf{x}_i + b) < 1, \text{ let } loss = 1 - y_i(w^T \mathbf{x}_i + b) \end{cases} \quad (19)$$

那么综合式 (19) 可得:

$$loss = \max\{0, 1 - y_i(w^T \mathbf{x}_i + b)\} \quad (20)$$

那么将这个错误 (loss) 加入到 Hard-Margin SVM 中, 可得:

$$\begin{cases} \min_{w,b} \frac{1}{2} w^T w + C \sum_{i=1}^N \max\{0, 1 - y_i(w^T \mathbf{x}_i + b)\} \\ s.t. \quad y_i(w^T \mathbf{x}_i + b) \geq 1 - \xi_i, i = 1, 2, \dots, N \end{cases} \quad (21)$$

引入 $\xi_i = 1 - y_i(w^T \mathbf{x}_i + b), \xi_i \geq 0$

$$\begin{cases} \min_{w,b,\xi} \frac{1}{2} w^T w + C \sum_{i=1}^N \xi_i \\ s.t. \quad y_i(w^T \mathbf{x}_i + b) \geq 1 - \xi_i, i = 1, 2, \dots, N \end{cases} \quad (21)$$

2 Kernel Method

这里对核方法从两个角度有两种解释:

1. 非线性带来的高维转换 (从模型角度): 由非线性可分的源数据经过非线性转换 $\phi(\mathbf{x})$ 得到线性可分的数据。

2. 对偶表示带来内积 (从优化角度)

对于 1. 的解释: 由简单的异或问题 (二维空间上线性不可分): $f(1, 1) = 1, f(0, 0) = 1, f(1, 0) = -1, f(0, 1) = -1$ 通过非线性转换即 $\mathbf{x} = (\mathbf{x}_1, \mathbf{x}_2) \xrightarrow{\phi(\mathbf{x})} \mathbf{z} = (\mathbf{x}_1, \mathbf{x}_2, (\mathbf{x}_1 - \mathbf{x}_2)^2)$, 此时在三维空间中四个点转换为 $f(1, 1, 0) = 1, f(0, 0, 0) = 1, f(1, 0, 1) = -1, f(0, 1, 1) = -1$ 那么这个时候就是线性可分的, 也就是说**高维比低维更易线性可分**。

对于 2. 的解释: 在 Hard-Margin SVM 中, 我们通过 Primal Problem(原始问题)(公式 (1)) 得到 Dual Problem(对偶问题)(公式 (11)) 其中 $x_i^T x_j$ 就是对 $\phi(x_i)^T \phi(x_j)$ 的解释。

那么将核方法应用在 SVM 中可以得到上面公式的对偶问题

$$\begin{cases} \max_{\alpha} -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j + \sum_{i=1}^N \alpha_i \\ s.t. \quad \alpha_i \geq 0 \end{cases} \quad (22)$$

在求解的时候需要求得内积，于是不可分数据在通过特征变换后，需要求得变换后的内积。我们常常很难求得变换函数的内积。于是直接引入内积的变换函数：

$$\begin{aligned} \forall \mathbf{x}, \mathbf{z} \in \chi, \exists \phi \in \mathcal{H} : \mathbf{x} \rightarrow \mathbf{z} \\ \text{s.t. } k(\mathbf{x}, \mathbf{z}) = \phi(\mathbf{x})^T \phi(\mathbf{z}) \end{aligned} \quad (23)$$

称 $k(\mathbf{x}, \mathbf{z})$ 为一个正定核函数，其中 \mathcal{H} 是 Hilbert 空间（完备的线性内积空间），如果去掉内积这个条件我们简单地称为核函数。

3 SMO 算法

对于如下凸二次规划问题：

$$\begin{cases} \max_{\alpha} -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j + \sum_{i=1}^N \alpha_i \\ \text{s.t. } \sum_{i=1}^N \alpha_i y_i = 0 \\ 0 \leq \alpha_i \leq C, \quad i = 1, 2, \dots, N \end{cases} \quad (24)$$

我们令

$$\mathcal{L} = -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j + \sum_{i=1}^N \alpha_i \quad (25)$$

那么

$$\begin{aligned} \mathcal{L}(\alpha_1, \alpha_2) = & \alpha_1 + \alpha_2 + \sum_{i=3}^N \alpha_i - \frac{1}{2} [\alpha_1 y_1 \alpha_2 y_2 \mathbf{x}_1^T \mathbf{x}_1 + 2\alpha_1 y_1 \alpha_2 y_2 \mathbf{x}_1^T \mathbf{x}_2 + 2 \sum_{j=3}^N \alpha_1 y_1 \alpha_j y_j \mathbf{x}_1^T \mathbf{x}_j \\ & + \alpha_2 y_2 \alpha_2 y_2 \mathbf{x}_2^T \mathbf{x}_2 + 2 \sum_{i=3}^N \alpha_2 y_2 \alpha_i y_i \mathbf{x}_2^T \mathbf{x}_i + \sum_{i=3}^N \sum_{j=3}^N \alpha_i y_i \alpha_j y_j \mathbf{x}_i^T \mathbf{x}_j] \end{aligned} \quad (26)$$

此处令 $\mathbf{x}_i^T \mathbf{x}_j = k_{ij}$ 那么

$$\mathcal{L}'(\alpha_1, \alpha_2) = \alpha_1 + \alpha_2 - \frac{1}{2} [\alpha_1^2 k_{11} + 2\alpha_1 y_1 \alpha_2 y_2 k_{12} + \alpha_2^2 k_{22} + 2 \sum_{j=3}^N \alpha_1 y_1 \alpha_j y_j k_{1j} + 2 \sum_{i=3}^N \alpha_2 y_2 \alpha_i y_i k_{2i}] \quad (27)$$

根据 $\sum_{i=1}^N \alpha_i y_i = 0$ 可以得出 $\alpha_1 y_1 + \alpha_2 y_2 + \sum_{i=3}^N \alpha_i y_i = 0$ ，这里我们令 $\sum_{i=3}^N \alpha_i y_i = -C$ (C 为常数)，可以得到 $\alpha_1 y_1 + \alpha_2 y_2 = C$ (或者可以写作 $\alpha_1^{\text{old}} y_1 + \alpha_2^{\text{old}} y_2 = C$)，所以 $\alpha_1 = (C - \alpha_2 y_2) y_1$ 然后代入式 (27) 可得

$$\begin{aligned} \mathcal{L}(\alpha_2) = & y_1 (C - \alpha_2 y_2) + \alpha_2 - \frac{1}{2} [(C - \alpha_2 y_2)^2 k_{11} + 2(C - \alpha_2 y_2) \alpha_2 y_2 k_{12} + \alpha_2^2 k_{22} \\ & + 2 \sum_{i=3}^N (C - \alpha_2 y_2) \alpha_i y_i k_{1i} + 2 \sum_{i=3}^N \alpha_2 y_2 \alpha_i y_i k_{2i}] \end{aligned} \quad (28)$$

对式 (28) 求偏导

$$\begin{aligned}
\frac{\partial \mathcal{L}}{\partial \alpha_2} &= -y_1 y_2 + 1 - \frac{1}{2} [2(C - \alpha_2 y_2)(-y_2)k_{11} + 2C y_2 k_{12} - 4\alpha_2 k_{12} + 2\alpha_2 k_{22} \\
&\quad - 2 \sum_{i=3}^N y_2 \alpha_i y_i k_{1i} + 2 \sum_{i=3}^N y_2 \alpha_i y_i k_{2i}] \\
&= 1 - y_1 y_2 - C y_2 k_{11} - \alpha_2 k_{11} - C y_2 k_{12} + 2\alpha_2 k_{12} - \alpha_2 k_{22} + \sum_{i=3}^N y_2 \alpha_i y_i k_{1i} \\
&\quad - \sum_{i=3}^N y_2 \alpha_i y_i k_{2i}
\end{aligned} \tag{29}$$

$$\frac{\partial \mathcal{L}}{\partial w} \Rightarrow w = \sum_{i=1}^N \alpha_i y_i \mathbf{x}_i$$

那么对于 $f(x_1)$ 可得以下推导

$$\begin{aligned}
f(\mathbf{x}_1) &= w^T \mathbf{x}_1 + b \\
&= \alpha_1 y_1 \mathbf{x}_1^T \mathbf{x}_1 + \alpha_2 y_2 \mathbf{x}_2^T \mathbf{x}_1 + \sum_{i=3}^N \alpha_i y_i \mathbf{x}_i^T \mathbf{x}_1 + b
\end{aligned} \tag{30}$$

那么扩展到 $i = 1, 2$

$$\begin{aligned}
f(\mathbf{x}_1) - \alpha_1 y_1 k_{11} - \alpha_2 y_2 k_{12} - b &= \sum_{i=3}^N \alpha_i y_i k_{1i} \\
f(\mathbf{x}_2) - \alpha_1 y_1 k_{12} - \alpha_2 y_2 k_{22} - b &= \sum_{i=3}^N \alpha_i y_i k_{2i}
\end{aligned} \tag{31}$$

因此式 (29) 中令对 α_2 的偏导为 0, 则

$$\begin{aligned}
\alpha_2^{new} (k_{11} + k_{22} - 2k_{12}) &= 1 - y_1 y_2 + C y_2 k_{11} - C y_2 k_{12} + \sum_{i=3}^N y_2 \alpha_i y_i k_{1i} - \sum_{i=3}^N y_2 \alpha_i y_i k_{2i} \\
&= y_2 (y_2 - y_1 + C k_{11} - C k_{12} + \sum_{i=3}^N \alpha_i y_i k_{1i} - \sum_{i=3}^N \alpha_i y_i k_{2i}) \\
&= y_2 (y_2 - y_1 + \alpha_1^{old} y_1 k_{11} + \alpha_2^{old} y_2 k_{11} - \alpha_1^{old} y_1 k_{12} - \alpha_2^{old} y_1 k_{12} \\
&\quad + f(x_1) - \alpha_1^{old} y_1 k_{11} - \alpha_2^{old} y_2 k_{12} - b - f(x_2) + \alpha_1^{old} y_1 k_{12} + \alpha_2^{old} y_2 k_{22} + b) \\
&= y_2 [f(x_1) - y_1 - (f(x_2) - y_2) + \alpha_2^{old} y_2 (k_{11} + k_{22} - 2k_{12})]
\end{aligned} \tag{32}$$

定义 $E_1 = f(\mathbf{x}_1) - y_1$, $E_2 = f(\mathbf{x}_2) - y_2$, $\eta = (k_{11} + k_{22} - 2k_{12})$ 所以综上变换式 (32) 为

$$\alpha_2 \eta = y_2 [(E_1 - E_2) + \alpha_2^{old} y_2 \eta] \tag{33}$$

所以可得

$$\alpha_2^{new} = \alpha_2^{old} + \frac{y_2 (E_1 - E_2)}{\eta} \tag{34}$$

根据式 $\alpha_1 y_1 + \alpha_2 y_2 = C$ 可得

$$\alpha_1^{new} = y_1(C - \alpha_2^{new} y_2) \quad (35)$$

那么根据式 (29)(30) 以及支持向量满足的表达式可得

$$\begin{aligned} w^T x_1 + b_1^{new} &= y_1 \\ b_1^{new} &= y_1 - w^T \mathbf{x}_1 \\ b_1^{new} &= y_1 - \alpha_1^{new} y_1 \mathbf{x}_1^T \mathbf{x}_1 - \alpha_2^{new} y_2 \mathbf{x}_2^T \mathbf{x}_1 - \sum_{i=3}^N \alpha_i y_i \mathbf{x}_i^T \mathbf{x}_1 \end{aligned} \quad (36)$$

根据 $E_i = f(x_i) - y_i$ 以及式 (30) 可得

$$\begin{aligned} E_1 &= w^T \mathbf{x}_1 + b - y_1 \\ &= \alpha_1^{old} y_1 \mathbf{x}_1^T \mathbf{x}_1 + \alpha_2^{old} y_2 \mathbf{x}_2^T \mathbf{x}_1 + \sum_{i=3}^N \alpha_i y_i \mathbf{x}_i^T \mathbf{x}_1 + b^{old} - y_1 \end{aligned} \quad (37)$$

式 (37) 做如下变换

$$y_1 - \sum_{i=3}^N \alpha_i y_i \mathbf{x}_i^T \mathbf{x}_1 = \alpha_1^{old} y_1 \mathbf{x}_1^T \mathbf{x}_1 + \alpha_2^{old} y_2 \mathbf{x}_2^T \mathbf{x}_1 + b^{old} - E_1 \quad (38)$$

带入式 (36) 得

$$\begin{aligned} b_1^{new} &= \alpha_1^{old} y_1 \mathbf{x}_1^T \mathbf{x}_1 + \alpha_2^{old} y_2 \mathbf{x}_2^T \mathbf{x}_1 + b^{old} - E_1 - \alpha_1^{new} y_1 \mathbf{x}_1^T \mathbf{x}_1 - \alpha_2^{new} y_2 \mathbf{x}_2^T \mathbf{x}_1 \\ &= -E_1 + y_1 \mathbf{x}_1^T \mathbf{x}_1 (\alpha_1^{old} - \alpha_1^{new}) + y_2 \mathbf{x}_2^T \mathbf{x}_1 (\alpha_2^{old} - \alpha_2^{new}) + b^{old} \end{aligned} \quad (39)$$

同理可得

$$b_2^{new} = -E_2 + y_1 \mathbf{x}_1^T \mathbf{x}_2 (\alpha_1^{old} - \alpha_1^{new}) + y_2 \mathbf{x}_2^T \mathbf{x}_2 (\alpha_2^{old} - \alpha_2^{new}) + b^{old} \quad (40)$$

那么对于 E_i 的求解如下

$$E_i^{new} = \sum_{j=1}^N y_j \alpha_j \mathbf{x}_i^T \mathbf{x}_j + b^{new} - y_i \quad (41)$$

将 $x_i^T x_j = k_{ij}$ 带入上式 (39), (40), (41) 并重新做出变换可得

$$b_1^{new} = -E_1 - y_1 k_{11} (\alpha_1^{new} - \alpha_1^{old}) - y_2 k_{21} (\alpha_2^{new} - \alpha_2^{old}) + b^{old} \quad (42)$$

$$b_2^{new} = -E_2 - y_1 k_{12} (\alpha_1^{new} - \alpha_1^{old}) - y_2 k_{22} (\alpha_2^{new} - \alpha_2^{old}) + b^{old} \quad (43)$$

$$E_i^{new} = \sum_{j=1}^N y_j \alpha_j k_{ij} + b^{new} - y_i \quad (44)$$